Université Ibn Tofaïl
جامعة ابن طفيل
Faculté des Sciences

Module Big Data

Mini Projet : Apache Spark MLlib

Prédiction de la réussite des étudiants

Réalisé par :**HEMANOU SAFAE**

Encadré par :**M.DERROUZ HATIM**

Année Universitaire

2025 - 2026

1. Introduction

Avec l'évolution rapide des technologies numériques, la quantité de données générées chaque jour connaît une croissance exponentielle. Les entreprises, les établissements d'enseignement, les réseaux sociaux et les objets connectés produisent d'importants volumes de données qui nécessitent des outils performants pour leur stockage, leur traitement et leur analyse. Ce phénomène est connu sous le nom de **Big Data**.

Le Big Data se caractérise principalement par trois dimensions : le volume des données, la vitesse à laquelle elles sont produites et la variété de leurs formats. Les méthodes traditionnelles de traitement de données deviennent souvent insuffisantes face à ces défis. C'est pourquoi de nouvelles technologies distribuées ont été développées afin de permettre le traitement efficace de grandes quantités d'informations.

Parmi ces technologies, **Apache Spark** est devenu l'un des frameworks les plus populaires dans le domaine du Big Data. Développé à l'origine à l'Université de Californie à Berkeley, Apache Spark est un moteur de calcul distribué conçu pour traiter de très grands ensembles de données de manière rapide et efficace. Contrairement aux approches traditionnelles basées uniquement sur le stockage disque, Spark utilise largement la mémoire vive (RAM), ce qui améliore considérablement les performances des traitements.

Apache Spark offre plusieurs bibliothèques spécialisées permettant de répondre à différents besoins d'analyse de données. Parmi elles, **Spark MLlib** est la bibliothèque dédiée au Machine Learning. Elle fournit un ensemble d'algorithmes permettant de réaliser des tâches telles que la classification, la régression, le clustering et les systèmes de recommandation. Grâce à son intégration native avec Spark, MLlib permet d'appliquer des techniques d'apprentissage automatique sur des données volumineuses tout en bénéficiant des capacités de calcul distribué.

Dans le cadre de ce mini-projet, nous allons exploiter Spark MLlib afin de développer un modèle de prédiction capable d'estimer la note d'un étudiant à partir de plusieurs caractéristiques académiques, notamment le nombre d'heures d'étude, le nombre d'absences et le niveau de participation. Pour cela, nous utiliserons un algorithme de régression linéaire permettant d'apprendre la relation entre ces variables et la note obtenue.

L'objectif principal de ce travail est de mettre en pratique les concepts fondamentaux d'Apache Spark et du Machine Learning à travers une application concrète. Ce projet permettra également de comprendre les différentes étapes d'un processus d'analyse prédictive, depuis le chargement et la préparation des données jusqu'à l'entraînement, l'évaluation et l'utilisation d'un modèle de prédiction.

2. Objectif du projet

L'objectif principal de ce mini-projet est de mettre en œuvre les fonctionnalités de Machine Learning proposées par Apache Spark MLlib afin de développer un modèle capable de prédire la note finale d'un étudiant à partir de plusieurs indicateurs académiques.

Dans le domaine de l'éducation, il est souvent important d'analyser les facteurs qui influencent les performances des étudiants afin d'améliorer leur suivi pédagogique et d'identifier les risques d'échec scolaire. Grâce aux techniques d'analyse prédictive, il est possible d'estimer les résultats futurs d'un étudiant en se basant sur certaines informations disponibles.

Pour ce projet, trois variables ont été sélectionnées comme facteurs explicatifs :

-Le nombre d'heures d'étude, qui représente le temps consacré à l'apprentissage ;

-Le nombre d'absences, qui reflète l'assiduité de l'étudiant ;

-Le niveau de participation en classe, qui mesure son implication dans les activités pédagogiques.

À partir de ces données, un modèle de régression linéaire sera construit à l'aide de la bibliothèque Spark MLlib. Ce modèle analysera les relations existantes entre les variables d'entrée et la note finale afin d'effectuer des prédictions sur de nouveaux cas.

Les objectifs spécifiques de ce travail sont les suivants :

-Découvrir l'environnement Apache Spark et sa bibliothèque MLlib ;

-Charger et manipuler des données à l'aide de PySpark ;

-Préparer les données pour leur utilisation dans un algorithme de Machine Learning ;

-Construire un modèle prédictif basé sur la régression linéaire ;

-Évaluer les performances du modèle à l'aide d'indicateurs appropriés ;

-Réaliser des prédictions sur de nouvelles données ;

-Comprendre les différentes étapes d'un projet d'analyse prédictive dans un environnement Big Data.

À travers ce mini-projet, nous cherchons non seulement à appliquer les concepts théoriques étudiés dans le module Big Data, mais également à démontrer comment les techniques de Machine Learning peuvent être utilisées pour extraire des informations utiles à partir des données et aider à la prise de décision.

3. Présentation du Dataset

Le dataset utilisé dans ce projet contient des informations académiques relatives à plusieurs étudiants. Chaque observation est décrite par trois variables explicatives : le nombre d'heures d'étude, le nombre d'absences et le niveau de participation en classe. La variable cible correspond à la note finale obtenue par l'étudiant. Ces données seront utilisées pour entraîner un modèle de régression linéaire capable de prédire les performances académiques de nouveaux étudiants.

HeuresEtude	Absences	Participation	Note
2	10	4	8
3	8	5	10
4	6	6	11
5	5	7	13
6	4	8	15
7	3	8	16
8	2	9	18
9	1	10	19
5	7	5	12
4	8	4	10

4. Prétraitement des données

Avant de construire le modèle de Machine Learning, les données ont été préparées à l'aide de PySpark dans l'environnement Google Colab.

Dans un premier temps, la bibliothèque PySpark a été installée puis une Spark Session a été créée afin d'utiliser les fonctionnalités d'Apache Spark.

Ensuite, le jeu de données contenant les informations des étudiants a été chargé sous forme de DataFrame Spark. Les options de lecture ont permis de récupérer automatiquement les noms des colonnes ainsi que les types de données.

Une phase d'exploration a ensuite été réalisée à l'aide des fonctions printSchema() et describe(). Cette étape a permis de vérifier la structure du dataset et d'obtenir des statistiques descriptives sur les différentes variables.

L'analyse a montré que toutes les colonnes sont de type numérique et qu'aucune valeur manquante n'est présente dans le jeu de données. Les données étaient donc prêtes à être utilisées pour l'entraînement du modèle de prédiction.

5. Construction du modèle

Après la préparation des données, un modèle de régression linéaire a été construit à l'aide de la bibliothèque Spark MLlib.

Dans un premier temps, les variables d'entrée (HeuresEtude, Absences et Participation) ont été regroupées dans une seule colonne appelée **features** grâce à l'outil VectorAssembler. Cette étape est nécessaire car les algorithmes de Machine Learning de Spark utilisent un vecteur de caractéristiques comme entrée.

Ensuite, le jeu de données a été divisé en deux parties : un ensemble d'entraînement représentant 80 % des données et un ensemble de test représentant 20 %. Cette séparation permet d'entraîner le modèle puis d'évaluer ses performances sur des données qu'il n'a jamais vues.

Par la suite, un modèle de régression linéaire a été créé et entraîné sur les données d'entraînement. L'objectif de cet algorithme est d'apprendre la relation entre les caractéristiques des étudiants et leur note finale afin de pouvoir effectuer des prédictions sur de nouvelles données.

6. Résultats obtenus

Une fois le modèle entraîné, des prédictions ont été réalisées sur l'ensemble de test. Les résultats obtenus montrent que les notes prédites sont proches des notes réelles, ce qui indique que le modèle a correctement appris les relations entre les différentes variables.

Afin d'évaluer la qualité du modèle, la métrique RMSE (Root Mean Square Error) a été utilisée. Cette mesure permet d'estimer l'écart moyen entre les valeurs réelles et les valeurs prédites. Plus la valeur du RMSE est faible, plus les prédictions sont précises.

Enfin, le modèle a été utilisé pour prédire la note d'un nouvel étudiant à partir de ses caractéristiques académiques (heures d'étude, absences et participation). Cette expérience a démontré la capacité du modèle à effectuer des prédictions sur de nouvelles données et à fournir une estimation de la performance future d'un étudiant.

7. Conclusion

Ce mini-projet a permis de mettre en pratique les concepts du Big Data et du Machine Learning à travers l'utilisation d'Apache Spark MLlib. L'objectif était de développer

un modèle capable de prédire la note d'un étudiant à partir de plusieurs caractéristiques académiques.

Les différentes étapes du projet ont consisté à préparer les données, construire un modèle de régression linéaire, évaluer ses performances et réaliser des prédictions sur de nouvelles données. Les résultats obtenus montrent que le modèle est capable d'estimer correctement les notes des étudiants à partir des informations disponibles.

Ce travail a permis de découvrir les principales fonctionnalités de Spark MLlib et de comprendre l'importance du Machine Learning dans l'analyse prédictive. À l'avenir, il serait possible d'améliorer ce projet en utilisant un jeu de données plus volumineux et en testant d'autres algorithmes de Machine Learning afin d'obtenir des prédictions encore plus précises.